

Minería de Datos

Sistema CRISP-DM — Análisis Completo

Dataset: Student Performance (UCI) — Portugués

Objetivo: Predecir si un estudiante aprobará (romantic)

Registros: 649

Features: 41

Docente: MILTON EDWARD HUMPIRI FLORES

Curso: Minería de Datos

Metodología: CRISP-DM — Cross-Industry Standard Process for Data Mining

ÍNDICE

1. Carga y Exploración de Datos (EDA)
2. Partición y Baseline — Data Leakage
3. Segmentación — K-Means y Clustering Jerárquico
4. Clasificación — Árbol de Decisión y Random Forest
5. Evaluación Comparativa de Modelos — Curva ROC
6. Matriz de Confusión con Métricas Completas
7. Conclusiones y Recomendaciones Gerenciales

1. Carga y Exploración de Datos (EDA)


El dataset **Student Performance** (UCI) contiene información demográfica, social y académica de estudiantes de secundaria en Portugal. Se usa el archivo de Portugués (649 registros, 33 variables). El objetivo es predecir si un estudiante aprobará el curso (*passed* = 1 si $G3 \geq 10$).

Variables clave del dataset:

Variable	Descripción
school	Escuela del estudiante (GP / MS)
age	Edad del estudiante
failures	Nº de materias reprobadas anteriormente
studytime	Horas de estudio semanales
absences	Nº de ausencias
Dalc / Walc	Consumo de alcohol (laboral / fin de semana)
G1, G2	Notas del 1er y 2do período (EXCLUIDAS — leakage)
G3	Nota final (origen del target passed)
passed	Target: 1 si $G3 \geq 10$, 0 en caso contrario

Calidad de Datos:

Métrica	Valor
Filas totales	649
Columnas	33
Valores nulos	0
Filas duplicadas	0
Clases en target	{'no': 410, 'yes': 239}



Proporción de Clases




Figura 1.1 — Distribución del target 'romantic'




Figura 1.2 — Distribuciones numéricas (histograma + media/mediana)




Figura 1.3 — Matriz de correlación de Pearson (triángulo inferior)

2. Partición y Baseline — Data Leakage

2.1 ¿Qué es el Data Leakage?

El **data leakage** ocurre cuando información del conjunto de prueba (o del futuro) se filtra al entrenamiento, causando que el modelo parezca más preciso de lo real. En este dataset, **G1 y G2** son calificaciones de períodos intermedios con correlación ≥ 0.85 con G3 — son excluidas obligatoriamente.

Medidas aplicadas para prevenir leakage:

Medida	Implementación
StandardScaler	Ajustado solo con X_train — transform aplicado a val/test
LabelEncoder	Aprende categorías solo del conjunto de entrenamiento
Partición estratificada	stratify=y preserva la proporción de clases en los 3 conjuntos
Estadísticas de imputación	Mediana/moda calculada solo en train
Detección automática	Variables con AUC > 0.95 son excluidas automáticamente

2.2 Esquema de Partición Train / Validación / Test

Conjunto	Tamaño	Uso
Train (65%)	519	Ajusta los parámetros del modelo
Validación (15%)	0	Selección de hiperparámetros
Test (20%)	130	Evaluación final — solo se usa una vez

2.3 Modelo Baseline

El **DummyClassifier(strategy='most_frequent')** predice siempre la clase mayoritaria. Representa el rendimiento mínimo que cualquier modelo útil debe superar. Dado que el dataset está desbalanceado (~84.6% aprobados), el baseline alcanza una Accuracy engañosamente alta — por eso se prioriza el **F1-Score** y **AUC-ROC**.

Métrica	Valor
Accuracy	0.6308
F1-Score	0.4880
AUC-ROC	0.5000 (aleatorio)
Estrategia	Most Frequent

3. Segmentación — K-Means y Clustering Jerárquico

El clustering es un aprendizaje **no supervisado** que agrupa registros similares sin usar la etiqueta. Permite descubrir **perfiles naturales de estudiantes**. Se usan variables numéricas de comportamiento: edad, educación parental, tiempo de estudio, ausencias, consumo de alcohol, etc.

3.1 K-Means Clustering

Algoritmo iterativo que agrupa n registros en K clústeres minimizando la *inercia* (suma de distancias cuadradas al centroide). El **método del codo** indica $K \approx 4$.




Figura 3.1 — Método del Codo y Silhouette Score para selección de K




Figura 3.2 — Diagrama Silhouette detallado por clúster (K-Means)




Figura 3.3 — Proyección PCA 2D de los clústeres K-Means




Figura 3.4 — Perfiles de clústeres: variables clave por grupo

Métrica	Valor
Silhouette Score	0.0504
Calificación	Sin estructura fuerte
K elegido	4

Nota: valores bajos de Silhouette son comunes en datos de comportamiento estudiantil, ya que los perfiles son continuos y no forman islas bien separadas.

3.2 Clustering Jerárquico (Ward)

Parte con cada registro como su propio clúster y los fusiona progresivamente. El criterio **Ward** minimiza la varianza interna. El **dendrograma** visualiza la jerarquía completa; cortando horizontalmente se

obtiene cualquier número de grupos.

3.3 Comparativa K-Means vs Jerárquico

El índice Silhouette evalúa qué tan bien asignado está cada punto: valores cercanos a +1 indican clústeres compactos y separados. K-Means es más escalable para grandes datasets; el jerárquico es más flexible y su dendrograma permite explorar la estructura sin definir K a priori.

Algoritmo	Silhouette	Escalabilidad	Requiere K a priori
K-Means	0.0504	Alta	Sí

4. Clasificación — Árbol de Decisión y Random Forest

La clasificación es un aprendizaje **supervisado** que aprende a predecir si un estudiante aprobará el curso (*passed* = 1) basándose en sus características demográficas, sociales y de comportamiento.

4.1 Árbol de Decisión (CART)

Divide el espacio de features con reglas binarias interpretables. Cada nodo hace una pregunta sobre una variable; las hojas son las predicciones. **Ventaja:** totalmente interpretable. **Limitación:** propenso a overfitting sin poda (*max_depth*, *min_samples_leaf*).

4.2 Random Forest

Ensemble de N árboles entrenados con muestras aleatorias del dataset (**bagging**) y subconjuntos aleatorios de features en cada nodo. La predicción final es la mayoría de votos. **Ventaja:** robusto, maneja no-linealidad, provee importancia de variables. **Limitación:** menos interpretable que un único árbol.

Resultados — Árbol de Decisión:

Métrica	Valor	Interpretación
Accuracy	0.5231	Proporción global de aciertos
F1-Score	0.5303	Balance Precisión/Sensibilidad
AUC-ROC	0.6249	Capacidad global de discriminación
Precisión	0.4167	$VP / (VP+FP)$
Sensibilidad	0.7292	$VP / (VP+FN)$

Resultados — Random Forest:

Métrica	Valor	Interpretación
Accuracy	0.5769	Proporción global de aciertos
F1-Score	0.3210	Balance Precisión/Sensibilidad
AUC-ROC	0.5589	Capacidad global de discriminación
Precisión	0.3939	$VP / (VP+FP)$
Sensibilidad	0.2708	$VP / (VP+FN)$




Figura 4.1 — Importancia de variables: Árbol de Decisión vs Random Forest

5. Evaluación Comparativa de Modelos — Curva ROC

5.1 Tabla Comparativa de Modelos

Modelo	Accuracy	F1-Score	Precisión	Sensibilidad	AUC-ROC
Regresión Logística	0.6615	0.5849	0.5345	0.6458	0.6250
Árbol de Decisión	0.5231	0.5303	0.4167	0.7292	0.6249
XGBoost	0.6462	0.4250	0.5312	0.3542	0.5986
LightGBM	0.6000	0.4348	0.4545	0.4167	0.5770
Naive Bayes	0.6231	0.3797	0.4839	0.3125	0.5694
Random Forest	0.5769	0.3210	0.3939	0.2708	0.5589
KNN	0.5615	0.2597	0.3448	0.2083	0.5307
Baseline (Dummy)	0.6308	0.4880	0.0000	0.0000	0.5000

Mejor modelo: Regresión Logística con AUC-ROC = 0.6250

5.2 Curvas ROC Superpuestas

La **curva ROC** muestra la tasa de Verdaderos Positivos (Sensibilidad) frente a la tasa de Falsos Positivos para todos los umbrales posibles. Un **AUC = 1.0** indica clasificador perfecto; **AUC = 0.5** equivale a adivinar al azar.




Figura 5.1 — Curvas ROC superpuestas — el modelo con mayor área es el mejor discriminador

5.3 Dashboard Comparativo




Figura 5.2 — Comparativa de Accuracy, F1-Score y AUC-ROC por modelo

5.4 Resumen para Equipo Gerencial

El modelo recomendado es **Regresión Logística**. En términos prácticos: si se ordenan 100 estudiantes por probabilidad de aprobar, el sistema coloca a un estudiante que **SÍ** aprobará antes que uno que **NO** aprobará el **62% de las veces**. El rendimiento global (AUC = 0.6250) es calificado como **necesita mejoras**. Se recomienda mejorar el modelo antes de implementarlo.

6. Matriz de Confusión con Métricas Completas

6.1 Estructura de la Matriz de Confusión

	Predicción: NO (0)	Predicción: SÍ (1)
Real: NO (0)	VN — Verdaderos Negativos	FP — Falso Positivo (Error Tipo I)
Real: SÍ (1)	FN — Falso Negativo (Error Tipo II)	VP — Verdaderos Positivos

Interpretación de cada celda:

Celda	Nombre	Significado práctico
VP	Verdaderos Positivos	Predijo 'aprobará' y sí aprobó → acierto correcto
VN	Verdaderos Negativos	Predijo 'no aprobará' y no aprobó → acierto correcto
FP	Falso Positivo — Error Tipo I	Predijo 'aprobará' pero NO aprobó → recurso mal dirigido
FN	Falso Negativo — Error Tipo II	Predijo 'no aprobará' pero SÍ aprobó → caso no detectado (más costoso)

6.2 Matrices de Confusión — Árbol y Random Forest




Figura 6.1 — Matriz de Confusión: Árbol de Decisión




Figura 6.2 — Matriz de Confusión: Random Forest

6.3 Métricas Derivadas de la Matriz de Confusión

Métrica	Fórmula	Cuándo priorizar
Precisión	$VP / (VP+FP)$	Cuando los FP son costosos (recursos mal dirigidos)
Sensibilidad	$VP / (VP+FN)$	Cuando los FN son costosos (caso no detectado)
Especificidad	$VN / (VN+FP)$	Para identificar correctamente los negativos
F1-Score	$2 \cdot VP / (2 \cdot VP + FP + FN)$	Balance entre Precisión y Sensibilidad
AUC-ROC	Área bajo curva ROC	Evaluación global independiente del umbral
VPP	$VP / (VP+FP)$	Valor Predictivo Positivo
VPN	$VN / (VN+FN)$	Valor Predictivo Negativo

Interpretación del mejor modelo (Regresión Logística):

Con una Sensibilidad de 0.6458, el modelo detecta el 64.6% de los estudiantes que realmente aprueban. La Especificidad de 0.6707 indica que identifica correctamente el 67.1% de los que no aprueban. **Recomendación de umbral:** para este problema educativo, priorizar la Sensibilidad (detectar a quienes van a reprobar) reduce el FN, aunque aumente ligeramente los FP.

7. Conclusiones y Recomendaciones Gerenciales

7.1 Resumen Ejecutivo

Aspecto	Resultado
Dataset	Student Performance (UCI) — 649 registros, 33 variables
Objetivo	Predecir si un estudiante aprobará ($G3 \geq 10$)
Leakage detectado	G1 y G2 excluidas ($r \geq 0.85$ con G3)
Desbalanceo	~84.6% aprobados $\rightarrow$ <code>class_weight='balanced'</code>
Segmentación	4 perfiles de estudiantes identificados
Variable más predictora	failures, absences, studytime, Walc
Metodología anti-leakage	Scaler y Encoder ajustados solo en train
Mejor modelo	Regresión Logística — $AUC=0.6250$, $F1=0.5849$

7.2 Hallazgos Principales

- **Leakage crítico:** G1 y G2 se correlacionan con G3 en más de 0.85. Su exclusión es obligatoria para un modelo real.
- **Desbalanceo:** el baseline (predecir siempre 'aprobó') alcanza ~84.6% de Accuracy, demostrando que esta métrica sola es engañosa.
- **Segmentación:** los 4 clústeres revelan perfiles diferenciados por dedicación al estudio vs. tiempo social/consumo de alcohol.
- **Random Forest supera al Árbol de Decisión** en todas las métricas al combinar múltiples árboles que se corrigen mutuamente.
- **Para el negocio educativo:** priorizar la Sensibilidad (detectar quienes van a reprobar) reduce el FN y el costo de intervención tardía.

7.3 Recomendaciones Prácticas

- Usar el modelo para priorizar tutorías en los estudiantes con probabilidad de aprobar $< 40\%$.
- Monitorear resultados trimestralmente y reentrenar con nuevos datos de cada cohorte.
- Considerar técnicas de resampling (SMOTE) o ajuste de `class_weight` para mejorar la detección de la clase minoritaria.
- Incluir variables de seguimiento en tiempo real (asistencia, participación) para mejorar la predicción.
- Presentar el modelo como una herramienta de apoyo, no como decisión definitiva, respetando el juicio docente.

Anexo: Dashboard Final de Resultados




Figura A.1 — Dashboard resumen completo: métricas, curvas ROC, importancia de variables y silhouette de clustering